

System wspomagania decyzji w wycenie diamentów

Analiza eksploracyjna oraz model regułowy

Maryia Audzei, IST, sem 4

MSiD Lab 17:05 TN (grupa 6)

1. Wstęp

Celem projektu jest analiza czynników wpływających na cenę diamentów oraz stworzenie prostego systemu wspomagania decyzji opartego na regułach. Inspiracją do podjęcia tego tematu była chęć zrozumienia, w jaki sposób parametry fizyczne oraz cechy jakościowe współgrają ze sobą, tworząc końcową wartość produktu.

W pracy analizowane są zależności pomiędzy ceną a cechami takimi jak:

- masa diamentu (carat),
- jakość szlifu (cut),
- kolor (color),
- przejrzystość (clarity),
- wymiary fizyczne.

Projekt obejmuje dwa podejścia: klasyfikację diamentów na „tanie” i „drogie” oraz regresję pozwalającą oszacować ich wartość.

Głównym założeniem jest stworzenie modelu regułowego, który będzie prosty, interpretowalny i oparty bezpośrednio na analizie danych.


2. Zbiór danych

Do realizacji projektu wykorzystano zbiór danych „diamonds”, zawierający informacje o diamentach oraz ich cenach. Zbiór obejmuje zarówno cechy numeryczne (np. masa, cena, wymiary), jak i kategoryjne (np. kolor, jakość szlifu, przejrzystość).

Najważniejszą zmienną w analizie jest cena (price), natomiast jednym z głównych predyktorów jest masa diamentu (carat), która – jak pokazuje dalsza analiza – ma kluczowy wpływ na wartość kamienia.


3. Analiza eksploracyjna (EDA)

a) Macierz korelacji + analiza ceny



Macierz korelacji stanowi punkt wyjścia do analizy zależności pomiędzy cechami numerycznymi. Najsilniejszą zależność obserwujemy pomiędzy masą diamentu a jego ceną, co wskazuje, że masa jest głównym czynnikiem wpływającym na wartość.


Dodatkowo analiza rozkładu cen przy użyciu wykresu pudełkowego pokazuje dużą zmienność oraz obecność wartości odstających. Na podstawie mediany ceny możliwe było wyznaczenie progu podziału na diamenty „tanie” i „drogie”, co stanowi fundament modelu klasyfikacyjnego.



Histogram rozkładu cen pozwala lepiej zrozumieć strukturę danych. Widać wyraźną asymetrię rozkładu – większość diamentów znajduje się w niższych przedziałach cenowych, natomiast liczba bardzo drogich kamieni jest znacznie mniejsza.

Taki rozkład wskazuje na obecność długiego „ogona” po prawej stronie, co oznacza, że wysokie ceny są rzadkie, ale mają duży wpływ na analizę. Obserwacja ta potwierdza zasadność wykorzystania mediany jako punktu podziału w modelu klasyfikacyjnym.



b) Zależność masa – cena



Wykres rozrzutu ujawnia nieliniowy charakter zależności między masą a ceną. Zamiast płynnego wzrostu obserwujemy wyraźne „skoki” wartości przy określonych poziomach masy.

Zjawisko to odzwierciedla rzeczywiste mechanizmy rynkowe – przekroczenie pewnych progów (np. 1 karat) znacząco zwiększa wartość diamentu. Na tej podstawie w modelu zastosowano podejście progowe zamiast klasycznej regresji liniowej.


c) Wpływ cech jakościowych



Analiza wykresów pudełkowych dla cech jakościowych pokazuje, że cena diamentu nie zależy wyłącznie od jego masy. Można zauważyć przypadki, w których mniejsze diamenty osiągają wysokie ceny dzięki lepszym parametrom jakościowym.

Wskazuje to na konieczność uwzględnienia dodatkowych reguł w modelu, które korygują decyzje wynikające wyłącznie z masy.


d) Jakość szlif



Średnia cena w zależności od jakości szlif ujawnia interesujące zjawisko – niektóre niższe klasy osiągają wyższe średnie wartości. Wynika to z obecności dużych diamentów w tych grupach, które zawyżają średnią.

Na tej podstawie wprowadzono regułę zapobiegającą błędnej klasyfikacji dużych, ale słabej jakości diamentów jako produktów premium.

e) Rozkład masy



Histogram masy pokazuje, że większość diamentów ma niewielką wagę. Dane są silnie skupione w dolnym zakresie wartości.

Pozwoliło to na wprowadzenie reguły eliminującej najmniejsze diamenty jako potencjalnie drogie, co zwiększa stabilność modelu.

4. Logika modelu

Model opiera się na zestawie reguł eksperckich wynikających bezpośrednio z analizy danych.

Podstawową regułą jest próg masy, który dzieli diamenty na „tanie” i „drogie”. Reguła ta została rozszerzona o dodatkowe warunki:

- bardzo małe diamenty są zawsze klasyfikowane jako tanie,
- diamenty o słabym szlifie nie są uznawane za drogie,
- wysoka jakość koloru może zwiększyć wartość diamentu.

W przypadku regresji zastosowano model schodkowy, który przypisuje ceny do określonych przedziałów masy zamiast wyliczać je w sposób ciągły.


5. Ocena modelu

Model został przetestowany na zbiorze testowym.

```
C:\infa\semester_4\metody_s_i_d_poprawione\metody_s_i_d>python main.py
Accuracy (simple): 0.9086948461253245
Accuracy (complex): 0.8755098257322952
MSE: 4471091.956803856
MAE: 1240.8162773451984
```

Uzyskane wyniki wskazują, że model osiąga wysoką skuteczność klasyfikacji pomimo swojej prostoty. Największe błędy pojawiają się w przypadku najdroższych diamentów, gdzie zależności są bardziej złożone.

6. Regresja – analiza wyników



Wykres przedstawiający zależność między wartościami rzeczywistymi a przewidywanymi pokazuje charakterystyczną strukturę wynikającą z zastosowania modelu regułowego.

Zamiast ciągłego rozkładu punktów obserwujemy strukturę pasmową, co wynika z przypisywania cen do określonych przedziałów.

Pomimo uproszczeń model dobrze odwzorowuje ogólny trend. Widoczna jest koncentracja punktów w pobliżu linii idealnej, co świadczy o poprawnym działaniu modelu dla większości przypadków.

Wraz ze wzrostem wartości diamentów rozrzut punktów zwiększa się, co wskazuje na rosnącą złożoność wyceny produktów luksusowych.

7. Wnioski

Przeprowadzona analiza pokazuje, że nawet prosty model regułowy może osiągnąć wysoką skuteczność, jeśli jego konstrukcja opiera się na rzetelnej analizie danych.

Najważniejszym czynnikiem wpływającym na cenę diamentu jest jego masa, jednak cechy jakościowe mają istotne znaczenie w przypadkach granicznych. Wprowadzenie dodatkowych reguł pozwoliło poprawić działanie modelu i ograniczyć błędy.

Z drugiej strony model ten ma swoje ograniczenia – szczególnie w przypadku bardzo drogich diamentów, gdzie zależności są bardziej złożone i trudniejsze do uchwycenia za pomocą prostych reguł.

W przyszłości możliwe byłoby zastosowanie bardziej zaawansowanych metod uczenia maszynowego, jednak zaproponowane rozwiązanie stanowi dobry przykład interpretowalnego systemu decyzyjnego.